# PEUT-ON ANTICIPER LE VOTE D'UNE COMMUNE ?

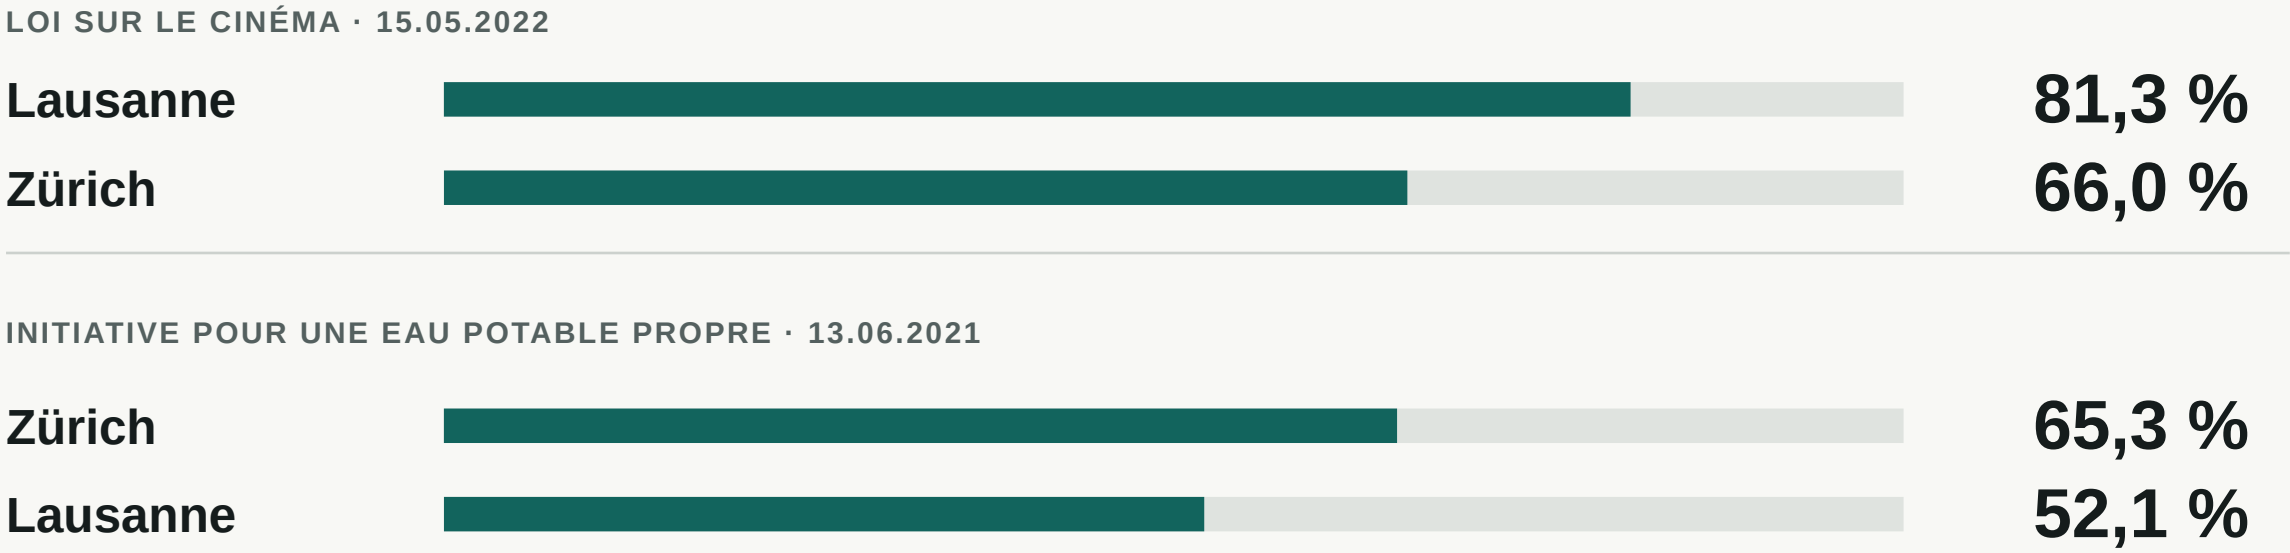
## Premier modèle. Premiers enseignements.

Un projet de prédiction des votations fédérales suisses, commune par commune.

Kimberly Beyeler, Romain Durussel, Victor Giordani, Abram Zweifel

# La réponse change avec la question.

Deux votations, deux communes : les écarts ne vont pas toujours dans le même sens.




Source : OFS / PR #70 · part de « oui » parmi les suffrages valables.

# Prédire une proportion. Pas un choix individuel.

Une observation = une commune × un objet de votation fédérale.

| COMMUNE | OBJET SOUMIS AU VOTE | RÉSULTAT OBSERVÉ |
|---|---|---|
| **Lausanne** | **Loi sur le cinéma** | **81,3 %** |

**part de « oui »** = $\frac{\text{OUI}}{\text{OUI + NON}}$ sur les suffrages valables

Cible = oui / (oui + non) ; les abstentions sont exclues du dénominateur.

# Six sources. Trois familles d’information.

Pour anticiper une proposition : connaître le lieu, le passé électoral et l’objet.

01 HISTORIQUE

## OFS · Votations

Résultats, historique des oui

02 COMMUNES

## OFS · STATPOP

Population, âge, nationalité

03 COMMUNES

## OFS · Élections

Force des partis

04 COMMUNES

## OFS · Typologies

Ruralité, région linguistique

05 OBJETS

## Swissvotes

Forme et domaines politiques

06 OBJETS

## Chancellerie

Brochures et explications[1]

[1] Texte extrait mais non intégré aux scores Ridge présentés.

Sources principales : OFS, Swissvotes, Chancellerie fédérale · répertoire OFS = source technique de raccordement.

# Avant le modèle, rendre les données fiables.

Une chaîne réexécutable : de plusieurs formats bruts à une table commune × objet.

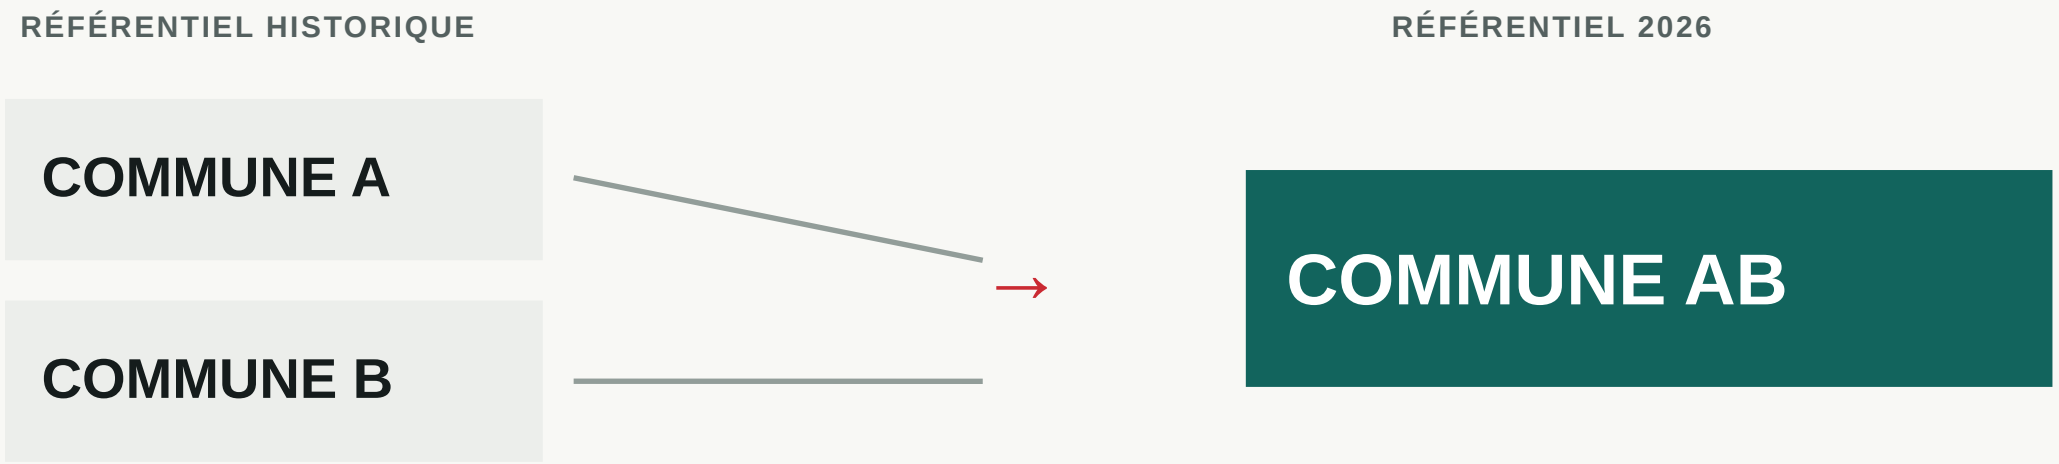
| 01 | 02 | 03 | 04 | 05 |
|---|---|---|---|---|
| **COLLECTER** | **NETTOYER** | **HARMONISER** | **ASSEMBLER** | **ÉVALUER** |
| PX · CSV · PDF | types · doublons | codes communaux | Parquet · audits | Ridge · métriques |

**À chaque étape : provenance, contrôles de jointure, exclusions et tests automatisés.**

Préparation des données : contributions de Romain (PR #54 et #57) et de toute l'équipe.

# Une commune change.
# Les données doivent suivre.

Les fusions imposent une harmonisation géographique cohérente.




**Règle de calcul** **additionner les effectifs, puis recalculer les pourcentages.**

Audit du 26.10.2026 : 2 105 communes ordinaires raccordées aux principales sources communales.

# Que sait le modèle avant chaque vote ?

Cinq familles de variables, ajoutées progressivement dans l’ablation.

| | | |
|---|---|---|
| A | **Historique** | moyenne des « oui » · nombre de scrutins |
| B | **Géographie** | région linguistique · urbain / rural |
| C | **Démographie** | population · âge · nationalité |
| D | **Partis** | forces électorales au Conseil national |
| E | **Objet** | forme juridique · domaines politiques |

PR #70 : groupes d’entrée de l’ablation Ridge ; brochures non utilisées dans ces scores.

# Ridge : une première hypothèse mesurable.

Régression linéaire régularisée : apprendre sans ajuster un coefficient à chaque bruit.

$$\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \ldots + \beta_n x_n$$

**$\alpha = 1$**

Pénalité L2 fixée pour comparer les variables, pas les réglages de l'algorithme.

PRÉTRAITEMENT (ENTRAÎNEMENT SEULEMENT)

**médiane → one-hot → standardisation → bornage [0, 1]**

Ridge α = 1 : même architecture et mêmes observations pour isoler les contributions des groupes.

# Une votation future ne doit pas entrer dans le passé.

Toutes les communes d’un scrutin restent ensemble : on sépare par dates.

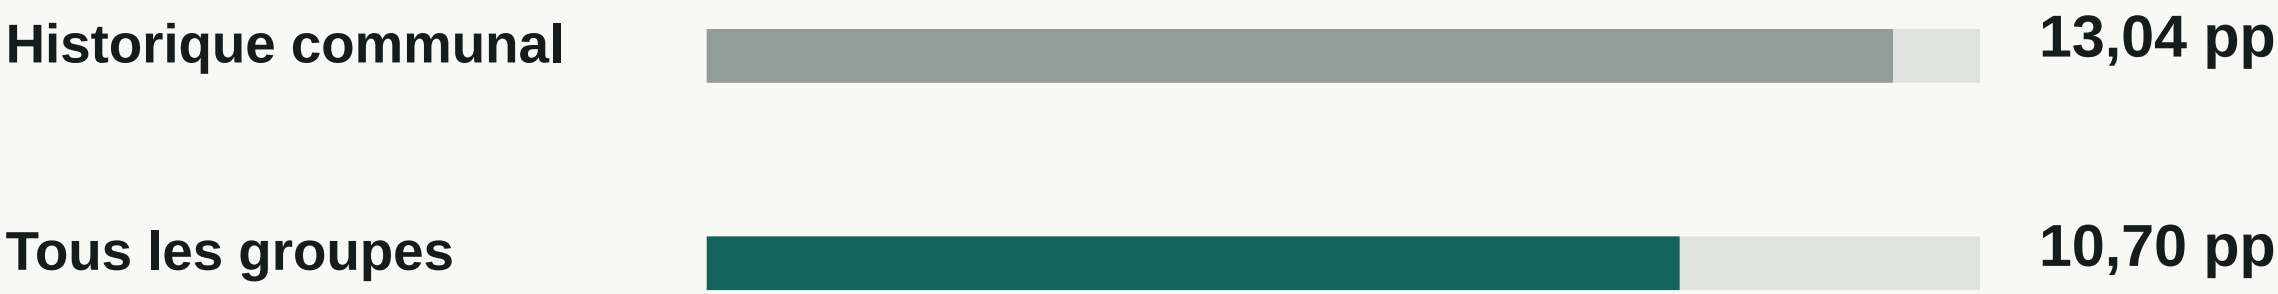
| ENTRAÎNEMENT | VALIDATION | TEST OUVERT |
|---|---|---|
| **2012–2020** | **2021–2022** | **2023–2025** |
| 83 objets · 30 dates | 24 objets · 7 dates | non vierge |

**Règle critique** **historique communal figé fin 2020 pour toute la validation.**

Ablation PR #70. 2023–2025 : test déjà consulté dans d’autres expériences du projet.

# Décrire l’objet politique change les prédictions.

Erreur moyenne absolue (MAE) en points de pourcentage · plus bas = mieux.




**– 18 %**

d’erreur moyenne en validation
dans cette comparaison exploratoire

Ridge α = 1 · validation 2021–2022 · 24 objets / 7 dates · exploration non confirmatoire.

# Presque tout le gain vient des caractéristiques de l’objet.

La paire historique + objet est très proche de la configuration complète.

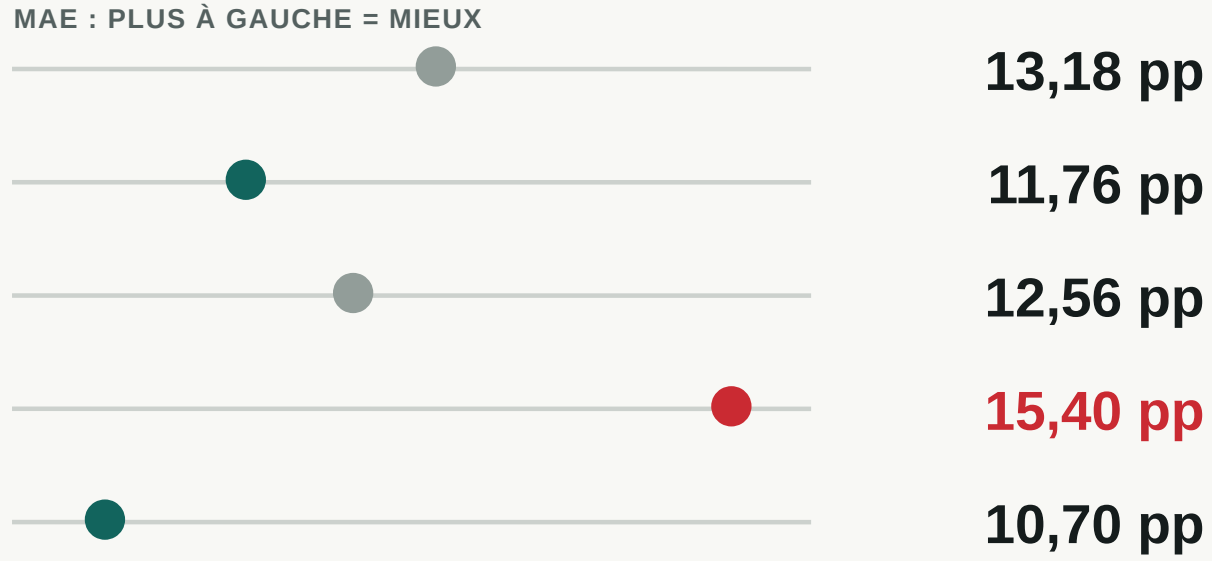
| 11,00 pp | 10,71 pp | 10,70 pp |
|---|---|---|
| OBJETS SEULS | HISTORIQUE + OBJETS | TOUS LES GROUPES |

**0,010 pp** d’écart entre les deux meilleurs ensembles mesurés.

Même Ridge et mêmes 50 520 lignes · écart non significativement établi.

# Ajouter des variables peut empirer les prédictions.

Même modèle, mêmes observations ; seule la description des objets change.




**15 objets sur 24** se dégradent avec les trois domaines sans forme juridique.

PR #70 : comparaison sur le même socle D · domaines thématiques et forme juridique.

# Réduire la complexité améliore la validation.

HistGradientBoostingRegressor : comparaison de quatre niveaux de régularisation.

MAE VALIDATION · PLUS BAS = MIEUX




**7,08 → 3,11 pp**

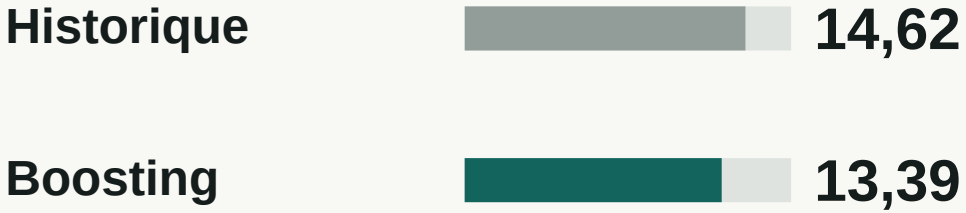
écart entraînement–validation réduit avec le modèle « très compact »

Branche 61 (non fusionnée) · validation rétrospective 2021–2022 · 24 objets / 7 dates.

# Une meilleure moyenne ne suffit pas.

HistGradientBoostingRegressor : amélioration moyenne et erreur majeure sur un objet.

MAE MOYENNE · 2023–2025




**– 1,24 pp**

13E RENTE AVS

**26,32 pp**

MAE du boosting sur cet objet

**contre 12,76 pp**

Notebook Romain, branche 61 (non fusionnée) : test rétrospectif 2023–2025 · 18 objets / 7 dates.

# Une chaîne technique complète. Pas un notebook isolé.

Collecte, données, documents, ML, visualisation et qualité du code.

### 01 COLLECTER

requests · PXWeb · pyjstat

### 02 PRÉPARER

pandas · NumPy · PyArrow

### 03 EXTRAIRE

PyMuPDF · Tesseract · OCR

### 04 MODÉLISER

scikit-learn · Ridge · boosting

### 05 VISUALISER

Jupyter · Matplotlib · GeoPandas

### 06 VÉRIFIER

GitHub Actions · pytest · Ruff

Stack réellement présente dans environment.yml et scripts/ ; Streamlit prévu, mais pas encore livré.

# Une bonne démonstration n’est pas encore une prévision.

Ce que le midterm permet de montrer — et ce qu’il ne permet pas encore.

**0**

## ligne strictement admissible

à ce stade de l’audit V1

## 24 objets / 7 dates

Les lignes communales ne sont pas des votes indépendants.

## Sources rétrospectives

La géographie et les éditions de 2026 ne prouvent pas leur disponibilité passée.

## Test déjà consulté

Les résultats 2023–2025 ne sont pas une confirmation encore vierge.

Audits modeling_v1 et expériences rétrospectives ; ces scores ne prouvent pas une prévision réelle.

# Le prochain gain doit être scientifiquement défendable.

Quatre priorités, dans un ordre qui évite de sur-optimiser un test déjà ouvert.

## 01 ÉTABLIR LES PREUVES

Dates de publication, versions des sources, géographie.

## 02 DIAGNOSTIQUER LES ERREURS

Analyse par objet/date ; stabilité de D3 et des catégories.

## 03 ENRICHIR LE SIGNAL

Brochures, recommandations, interactions commune × objet.

## 04 VALIDER ET LIVRER

Protocole gelé, période non consultée, application claire.

Les brochures sont collectées et extraites ; leur exploitation ML exige une validation de disponibilité.

CE QUE NOUS RETENONS

# Le défi n’est pas seulement de connaître les communes.

## C’est d’anticiper leur réaction à une proposition encore inconnue.

QUESTIONS ?

# Les chiffres, selon leur périmètre.

Les tables de préparation et les partitions expérimentales ne couvrent pas exactement les mêmes observations.

| | | |
|---|---|---|
| Résultats OFS historiques | **1 025 903** | lignes source |
| Table structurée exploratoire | **262 981** | 125 objets · 44 dates |
| V1 préparée auditée | **304 616** | 144 objets · 51 dates |
| **V1 strictement admissible** | **0** | preuves de disponibilité manquantes |
| Ablation Ridge : entraînement | **174 571** | 83 objets · 30 dates |
| Ablation Ridge : validation | **50 520** | 24 objets · 7 dates |

Sources : audit pipeline 26.10 ; modeling_v1 31.10 ; ablation Ridge PR #70, 03.11.2026.

# Références et reproductibilité.

Données, code, tests et résultats documentés dans le dépôt GitHub.

| | |
|---|---|
| **Dépôt principal** | github.com/VictorGTheCoder/GML-Swiss-Voting |
| **Cahier des charges** | Groupe 2 — Swiss referendums (PDF) |
| **Ablation Ridge** | PR #70 · scripts, CSV, figures et rapport |
| **Boosting · Romain** | Branche 61 · notebook et expériences |
| **Linéaire régularisé** | PR #73 · Ridge, Lasso, Elastic Net |
| **Audit de la V1** | docs/project/modeling_v1_audit.md |
| **Données et outils** | environment.yml · scripts/ · tests/ |

Romain : branche boosting 61 non fusionnée ; ablation Ridge PR #70 et régression PR #73 non fusionnées.